

涉密论文 ☐ 公开论文 ☐

浙江大学

本科生毕业论文



题目 基于增量奇异值分解的参数化 PDE 降阶方法研究

学生姓名 钱周越

学生学号 3220104074

指导教师 李雨文

年级与专业 2022级信息与计算科学

所在学院 数学科学学院

递交日期 2026 年 5 月 8 日

浙江大学本科毕业论文（设计）承诺书

1. 本人郑重地承诺所呈交的毕业论文（设计），是在指导教师的指导下严格按照学校和学院有关规定完成的。

2. 本人在毕业论文（设计）中除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得浙江大学或其他教育机构的学位或证书而使用过的材料。

3. 与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

4. 本人承诺在毕业论文（设计）工作过程中没有伪造数据等行为。

5. 若在本毕业论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

6. 本人完全了解浙江大学有权保留并向有关部门或机构送交本论文（设计）的复印件和磁盘，允许本论文（设计）被查阅和借阅。本人授权浙江大学可以将本论文（设计）的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编本论文（设计）。

作者签名：

导师签名：

签字日期：

年 月 日

签字日期

年 月 日

致谢

首先，我要衷心感谢我的导师李雨文教授，在整个毕业论文的研究过程中给予了我无私的指导和支持。李雨文教授不仅在学术上提供了宝贵的建议，还在我遇到困难时给予了耐心的鼓励和帮助，使我能够顺利完成这项研究。

摘要

为了解决参数化偏微分方程在多查询场景下有限元求解成本过高的问题, 本文将增量奇异值分解 (ISVD) 应用于模型降阶. 在梳理加权内积下 core SVD 理论的基础上, 针对经典 Brand 增量算法在长序列更新中因舍入误差累积导致的正交性退化, 复现了 Zhang (2022) 的改进算法. 该算法通过累积更新策略避免小正交矩阵的连续乘积, 从机制上消除了频繁重正交化的必要性. 在一维和二维参数化椭圆型 PDE 上的数值实验表明, 改进的 ISVD 能够长期保持加权正交性, 逼近精度与批次 POD 相当, 同时峰值内存压缩一个数量级以上, 离线时间显著缩短. 本文为大规模参数化 PDE 的高效降阶提供了一种兼具数值稳定性与计算效率的可行方案.

关键词: 模型降阶; 偏微分方程; 增量奇异值分解; 正交性; 内存占用

Abstract

To mitigate the high computational cost of solving parametrized PDEs in many-query scenarios, this thesis applies incremental singular value decomposition (ISVD) to model order reduction. After reviewing the core SVD theory under weighted inner products, we reproduce the improved ISVD by Zhang (2022), which overcomes the orthogonality degradation in the classical Brand algorithm caused by rounding error accumulation. By avoiding the chain multiplication of small orthogonal matrices, the improved algorithm removes the need for frequent reorthogonalization. Numerical experiments on 1D and 2D parametrized elliptic PDEs demonstrate that the improved ISVD maintains weighted orthogonality over long update sequences, achieves approximation accuracy comparable to batch POD, reduces peak memory by over an order of magnitude, and significantly cuts offline computation time. This work provides a numerically stable and computationally efficient solution for reduced-order modeling of large-scale parametrized PDEs.

Keywords: Model Order Reduction; Partial Differential Equations; Incremental SVD; Orthogonality; Memory Usage

目录

第一部分 毕业论文（设计）

1	绪论	1
1.1	研究背景与重要意义	1
1.2	从 Batch SVD 到增量 SVD 的必要性	1
1.3	加权核心 SVD	2
1.4	本文主要工作与创新点	3
2	PDE 降阶的数学映射与增量奇异值分解	5
2.1	参数化椭圆 PDE 的有限元离散与降阶	5
2.2	加权 Core SVD	5
2.3	Brand 经典增量 SVD 算法	5
3	改进算法的数学原理	7
3.1	正交性退化的根源与开放问题	7
3.2	Zhang 改进算法的数学结构	7
3.3	复杂度分析	12
4	Many-Query PDE 求解中采用 ISVD 的完整流程	12
4.1	整体流程概述	12
4.2	增量 SVD 在离线构基中的核心作用	13
5	数值实验与性能分析	14
5.1	增量 SVD 算法基准测试	14
5.1.1	正交性演化	14
5.1.2	分解正确性验证	15
5.2	1D 参数化 PDE 实验	16
5.2.1	离线构基时间对比	16
5.2.2	正交性对比	17
5.2.3	单步时间差分析	17
5.3	基于两个参数的大规模 PDE 实验	18
5.4	基于三个参数的大规模 PDE 实验	19

6 结论与未来展望	21
6.1 结论	21
6.2 未来展望	21
7 参考文献	23
附录：Incremental SVD 核心更新模块代码实现	25
作者简介	31
本科生毕业论文（设计）任务书	33
本科生毕业论文（设计）考核	35

第二部分 毕业论文（设计）开题报告

一、 文献综述	1
1 背景介绍	1
1.1 小节	1
1.2 小节	1
2 国内外研究现状	1
2.1 研究方向及进展	1
2.2 存在问题	1
3 研究展望	1
二、 开题报告	3
1 问题提出的背景	3
1.1 背景介绍	3
1.1.1 项目提出的原因	3
2 本研究的意义和目的	3
3 项目的主要内容和技術路线	3
3.1 主要研究内容	3
3.2 技术路线	3
3.3 可行性分析	3
4 研究计划进度安排及预期目标	3

4.1 进度安排	3
4.2 预期目标	3
三、 外文翻译	5
1 节标题	5
四、 外文原文	7
毕业论文（设计）文献综述和开题报告考核	11

第一部分

毕业论文（设计）

1 绪论

1.1 研究背景与重要意义

参数化偏微分方程 (PDE) 广泛出现在热传导、流体力学、电磁场以及多物理场耦合等问题中. 在工程设计与科学计算中, 常面临所谓的 **many-query** 场景: 需要在大量不同参数下反复求解同一族方程, 例如参数识别、优化设计、不确定性量化等^[1-2]. 采用有限元方法 (FEM) 离散后, 得到的大规模代数系统 $A(\mu)u_h(\mu) = f(\mu)$ 维数 N 通常很大, 单次求解已属昂贵; 若对每个参数点独立求解, 总成本难以承受.

缩减基 (Reduced Basis, RB) 方法通过构造低维子空间 $V_r \in \mathbb{R}^{N \times r}$ ($r \ll N$) 将高维系统投影至该子空间, 获得降阶模型:

$$V_r^T A(\mu) V_r a(\mu) = V_r^T f(\mu), \quad (1-1)$$

从而在在线阶段实现极快求解^[1].

1.2 从 Batch SVD 到增量 SVD 的必要性

缩减基方法的核心思想是将高维有限元解空间投影到一个低维子空间上, 从而大幅降低求解规模. 具体而言, 对于参数化 PDE 离散后得到的代数系统 $A(\mu)u_h(\mu) = f(\mu)$, 若已知一组基向量 $V_r \in \mathbb{R}^{N \times r}$ ($r \ll N$), 则近似解可表示为 $u_h(\mu) \approx V_r a(\mu)$. 代入原方程并施加 Galerkin 投影, 得到降阶模型:

$$V_r^T A(\mu) V_r a(\mu) = V_r^T f(\mu), \quad (1-2)$$

其中系数矩阵的规模仅为 $r \times r$, 在线求解速度极快. 因此, 投影降阶的核心问题转化为: 如何构造一个最优的低维子空间 V_r , 使得对所有感兴趣参数 μ , 投影误差 $\|u_h(\mu) - V_r V_r^T u_h(\mu)\|$ 足够小.

构造该子空间最常用的方法为本征正交分解 (POD). 给定一组快照 (snapshots) $\{u_h(\mu_i)\}_{i=1}^m$, 将其排列为快照矩阵 $U = [u_h(\mu_1), \dots, u_h(\mu_m)] \in \mathbb{R}^{N \times m}$. 对 U 执行奇异值分解 $U = \Phi \Sigma \Psi^T$, 取前 r 个左奇异向量组成 $V_r = \Phi(:, 1:r)$. POD 保证在 Frobenius 范数意义下, V_r 是所有秩 r 子空间中对快照集逼近最优的.

然而，经典（批处理）SVD 要求事先收集全部 m 个快照才能一次性分解，这在实际应用中面临三大瓶颈：

1. **计算负担重：**对 $U \in \mathbb{R}^{N \times m}$ 进行 SVD 的复杂度为 $\mathcal{O}(Nm^2)$ （若 $N \geq m$ ），当快照数 m 或自由度 N 较大时难以承受；
2. **内存开销高：**必须同时存储所有历史快照，内存需求随 m 线性增长，对于大规模 PDE 或大量采样点极易耗尽内存；
3. **不适应流式生成：**在参数空间的贪婪采样、自适应加密或实时数据同化中，快照是按顺序逐个获得的（ $U_{\ell+1} = [U_{\ell} \ u_{\ell+1}]$ ）。批处理模式只能等待全部数据就绪，无法利用已有分解结果进行增量更新。

为解决上述问题，增量奇异值分解（Incremental SVD, ISVD）应运而生。它能够在已有 SVD 分解 $U_{\ell} \approx \Phi_{\ell} \Sigma_{\ell} \Psi_{\ell}^T$ 的基础上，当新快照 $u_{\ell+1}$ 加入时，仅以 $\mathcal{O}(Nr^2)$ 甚至更低的代价将分解更新到 $U_{\ell+1}$ 。相比从头计算 SVD，ISVD 不仅显著降低了计算和存储需求，还天然适配快照逐步生成的流程。因此，研究高效、数值稳定的增量 SVD 算法，对于构建可扩展的缩减基方法具有重要的理论意义和工程价值。

1.3 加权核心 SVD

由于快照来自有限元离散，其内积自然采用加权形式：

$$\langle u, v \rangle_W = u^T W v, \quad W = M \quad (\text{质量矩阵}) \text{ 或 } W = K \quad (\text{刚度矩阵}), \quad (1-3)$$

而非标准欧几里得内积。为与连续问题中的能量结构一致，须采用核心 SVD (core SVD)：

$$U = Q \Sigma R^T, \quad Q^T W Q = I, \quad R^T R = I, \quad (1-4)$$

其中 $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$ 且 $\sigma_1 \geq \dots \geq \sigma_r > 0$ ^[3]。当 $W = I$ 时退化为标准 SVD。忽略加权内积会导致提取的基在物理能量意义下不正交，降阶模型可能失效。

1.4 本文主要工作与创新点

本文立足于参数化偏微分方程模型降阶的实际需求，围绕增量奇异值分解 (ISVD) 的数值稳定性与计算效率展开系统研究。

首先，完整复现了加权 core SVD 框架与 Brand 经典增量算法，通过数值实验揭示了其正交性随更新次数累积而迅速退化的本质原因——小正交矩阵连乘导致的舍入误差放大。在此基础上，深入分析了 Zhang (2022) 改进算法的数学机制，阐释了其如何通过累积更新策略从根本上避免矩阵连乘，进而回答了 Brand 于 2006 年提出的关于重正交化频率的开放问题。为了验证理论分析的有效性，本文在 1D 和 2D 参数化椭圆型 PDE 上开展了系统性的数值实验，全面对比了批次 POD、经典 Brand ISVD 与 Zhang 改进 ISVD 在降阶精度、加权正交性、离线构基时间以及峰值内存占用等方面的表现。实验结果表明，改进的 ISVD 能够在不依赖频繁重正交化的前提下，长期保持加权正交性稳定，同时大幅压缩内存开销并提升离线计算效率。这些工作为大规模 many-query 场景下的 PDE 降阶提供了一套兼具数值稳健性与计算经济性的可行方案。

本文的主要工作与贡献如下：

1. 在加权内积框架下，完整实现了 core SVD 的 batch 版本和 Brand 经典增量算法。通过数值实验发现：当快照数超过 400 时，Brand 算法的加权正交性误差 $\|I - Q^T W Q\|_F$ 从 10^{-15} 急剧恶化至 10^1 ，导致截断策略失效。
2. 复现并分析了 Zhang (2022) 的改进算法，揭示了“累积更新”避免小正交矩阵连乘的数学机制。实验表明，在相同条件下，改进算法的正交性误差始终保持在 10^{-8} 以下。
3. 在 2D 参数化椭圆型 PDE（自由度 $N = 3600$ ，快照数 $m = 1000$ ）上，改进 iSVD 的峰值内存从 batch 模式的 35.10 MB 降至 2.16 MB（压缩 16.2 倍）。

2 PDE 降阶的数学映射与增量奇异值分解

2.1 参数化椭圆 PDE 的有限元离散与降阶

考虑含参数 $\mu \in \mathcal{P} \subset \mathbb{R}^p$ 的椭圆型方程：

$$-\nabla \cdot (a(x; \mu) \nabla u(x; \mu)) = f(x), \quad x \in \Omega, \mu \in \mathcal{P} \subset \mathbb{R}^p, \quad (2-5)$$

配以齐次 Dirichlet 边界条件. 经有限元法 (FEM) 离散得到：

$$A(\mu)u_h(\mu) = f(\mu), \quad A(\mu) \in \mathbb{R}^{N \times N}, u_h(\mu) \in \mathbb{R}^N, N \gg 1. \quad (2-6)$$

令 $V_r \in \mathbb{R}^{N \times r}$ 为 POD 基, 近似 $u_h(\mu) \approx V_r a(\mu)$, Galerkin 投影得降阶系统：

$$V_r^T A(\mu) V_r a(\mu) = V_r^T f(\mu), \quad (2-7)$$

截断误差由小奇异值平方和 $\sum_{i>r} \sigma_i^2$ 控制.

2.2 加权 Core SVD

定义^[3]：给定对称正定权矩阵 W , 矩阵 U 的 core SVD 为满足 $Q^T W Q = I$ 和 $R^T R = I$ 的分解 $U = Q \Sigma R^T$, 其中 Σ 为对角奇异值矩阵. 该分解可通过广义 SVD 获得, 亦可由 Cholesky 分解 $W = L L^T$ 转化为标准 SVD: 令 $\tilde{U} = L^T U$, 计算 $\tilde{U} = \tilde{Q} \Sigma R^T$, 则 $Q = L^{-T} \tilde{Q}$.

2.3 Brand 经典增量 SVD 算法

针对快照矩阵按列扩展 $U_{\ell+1} = [U_\ell \mid u_{\ell+1}]$ 的流式到达特性, Brand (2002) 提出了经典增量更新算法^[4]. 其功能是在已知 U_ℓ 的 rank- k core SVD $U_\ell = Q \Sigma R^T$ 的前提下, 利用新列 $u_{\ell+1}$ 快速获得 $U_{\ell+1}$ 的更新分解. 算法步骤如下：

1. 计算投影坐标与加权残差：

$$d = Q^T (W u_{\ell+1}), \quad e = u_{\ell+1} - Q d, \quad p = \sqrt{e^T W e}. \quad (2-8)$$

若 $p > 0$ 令 $\tilde{e} = e/p$, 否则 $\tilde{e} = 0$.

2. 构造核心矩阵 $Y = \begin{bmatrix} \Sigma & d \\ 0 & p \end{bmatrix} \in \mathbb{R}^{(k+1) \times (k+1)}$, 并计算其完全 SVD: $Y = Q_Y \Sigma_Y R_Y^T$.

3. 更新分解:

$$Q \leftarrow [Q \mid \tilde{e}]Q_Y, \quad \Sigma \leftarrow \Sigma_Y, \quad R \leftarrow \begin{bmatrix} R & 0 \\ 0 & 1 \end{bmatrix} R_Y. \quad (2-9)$$

若 p 小于容差则秩不增, 更新公式做相应截断 (详见^[4]).

该算法将高维更新归结为对 $(k+1) \times (k+1)$ 小矩阵的 SVD, 单步复杂度 $\mathcal{O}(k^3)$, 远低于重算全矩阵. 然而式 (2-9) 中 $[Q \mid \tilde{e}]Q_Y$ 涉及 Q 与 Q_Y 的乘法, 且 Q_Y 来自多次更新链的连乘, 浮点误差累积将导致 $Q^T W Q$ 严重偏离单位矩阵, 即产生正交性退化.

分块矩阵验证 为严格验证更新公式的正确性, 考虑扩展后的快照矩阵 $U_{\ell+1} = [U_\ell, u_{\ell+1}]$. 利用 $U_\ell = Q \Sigma R^T$ 及 $u_{\ell+1} = Qd + p\tilde{e}$, 有:

$$U_{\ell+1} = [Q \Sigma R^T, Qd + p\tilde{e}] = [Q, \tilde{e}] \begin{bmatrix} \Sigma R^T & d \\ 0 & p \end{bmatrix}. \quad (2-10)$$

记 $\tilde{R} = \begin{bmatrix} R & 0 \\ 0 & 1 \end{bmatrix}$, 则上式化为

$$U_{\ell+1} = [Q, \tilde{e}] \begin{bmatrix} \Sigma & d \\ 0 & p \end{bmatrix} \tilde{R}^T. \quad (2-11)$$

对 $Y = \begin{bmatrix} \Sigma & d \\ 0 & p \end{bmatrix}$ 做 SVD $Y = Q_Y \Sigma_Y R_Y^T$, 代入得

$$U_{\ell+1} = ([Q, \tilde{e}]Q_Y) \Sigma_Y (\tilde{R}R_Y)^T, \quad (2-12)$$

此即式 (2-9) 给出的分解. 该推导将高维更新归结为小矩阵 Y 的 SVD, 从代数上保证了更新步骤的完备性.

3 改进算法的数学原理

3.1 正交性退化的根源与开放问题

Brand 在 2006 年指出：“为了保证一定的整体数值精度水平，需要多久进行一次重正交化是一个开放问题；这不会改变整体复杂度。”^[5] 其根源在于：每次更新均需将小正交矩阵 Q_Y 乘入 Q ，形成连乘积 $Q \leftarrow Q \prod Q_Y^{(i)}$ 。即使每个 $Q_Y^{(i)}$ 在机器精度下严格正交，有限精度浮点运算下的连乘仍会累积舍入误差，导致 Q 失去加权正交性。此外，右奇异空间的更新需反复计算伪逆，进一步加剧数值不稳定。传统的加权 Gram-Schmidt 重正交化虽可缓解，但计算开销巨大，尤其在加权内积下^[3]。

3.2 Zhang 改进算法的数学结构

Zhang (2022) 通过严格的数学重组，给出了对上述开放问题的决定性回答：通过避免小正交矩阵的连乘，彻底消除了对内部因子重正交化的必要性^[6]。以下给出关键引理与定理。

引理 1 (秩不增时的 SVD 结构). 设 $A \in \mathbb{R}^{k \times k}$, $\alpha \in \mathbb{R}^k$, 且 $Q_1 \Sigma_1 R_1^T$ 为 $[A \mid \alpha]$ 的薄 SVD. 则

$$\begin{bmatrix} Q_1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} R_1^T \\ r_{k+1}^T \end{bmatrix} \quad (3-13)$$

是 $\begin{bmatrix} A & \alpha \\ 0 & 0 \end{bmatrix}$ 的一个 SVD, 其中 $r_{k+1} \in \mathbb{R}^{k+1}$ 是单位向量且与 R_1 的各列正交。

证明： 直接验证可知， $\begin{bmatrix} Q_1 & 0 \\ 0 & 1 \end{bmatrix}$ 和 $\begin{bmatrix} R_1 & r_{k+1} \end{bmatrix}$ 均为正交矩阵，且

$$\begin{bmatrix} Q_1 & 0 \\ 0 & 1 \end{bmatrix}^T \begin{bmatrix} A & \alpha \\ 0 & 0 \end{bmatrix} \begin{bmatrix} R_1 & r_{k+1} \end{bmatrix} = \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix}. \quad (3-14)$$

该等式右端即为奇异值矩阵，因此左端构成了原矩阵的 SVD. $\square$

该引理说明，当新快照的残差范数 $p = 0$ 时，更新过程可自然嵌入零块结构，为后续累积更新奠定基础。

定理 1 (两步累积更新). 设 $Q\Sigma R^T$ 为 U_ℓ 的 rank- k core SVD, 且两个新快照 $u_{\ell+1}, u_{\ell+2}$ 满足 $p_1 = p_2 = 0$ (即秩不减). 令

$$M_2 = [\Sigma \mid Q^T W u_{\ell+1} \mid Q^T W u_{\ell+2}] \in \mathbb{R}^{k \times (k+2)}, \quad (3-15)$$

并计算其薄 SVD $M_2 = \widehat{Q}\widehat{\Sigma}\widehat{R}^T$. 则更新

$$Q \leftarrow Q\widehat{Q}, \quad \Sigma \leftarrow \widehat{\Sigma}, \quad R \leftarrow \begin{bmatrix} R & 0 \\ 0 & I_2 \end{bmatrix} \widehat{R} \quad (3-16)$$

与逐次应用 Brand 更新所得结果完全一致, 且 $\widehat{Q}$ 与 $\widehat{R}$ 自动保持正交.

证明: 由于 $p_1 = 0$, 有 $u_{\ell+1} = Qd_1$, 其中 $d_1 = Q^T W u_{\ell+1}$. 首先对 $U_{\ell+1} = [U_\ell \mid u_{\ell+1}]$ 应用 Brand 更新. 由式 (2.2) 及 $p_1 = 0$ 得:

$$U_{\ell+1} = Q \begin{bmatrix} \Sigma & d_1 \end{bmatrix} \begin{bmatrix} R & 0 \\ 0 & 1 \end{bmatrix}^T. \quad (3-17)$$

令 $Y_1 = \begin{bmatrix} \Sigma & d_1 \end{bmatrix} \in \mathbb{R}^{k \times (k+1)}$. 设 Y_1 的薄 SVD 为 $Y_1 = Q_{(1)}\Sigma_{(1)}R_{(1)}^T$, 其中 $Q_{(1)} \in \mathbb{R}^{k \times k}$ 正交, $\Sigma_{(1)} \in \mathbb{R}^{k \times k}$ 对角, $R_{(1)} \in \mathbb{R}^{(k+1) \times k}$ 满足 $R_{(1)}^T R_{(1)} = I_k$. 则根据引理 1, 矩阵 $\begin{bmatrix} \Sigma & d_1 \\ 0 & 0 \end{bmatrix}$ 的 SVD 可构造为:

$$\begin{bmatrix} \Sigma & d_1 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} Q_{(1)} & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \Sigma_{(1)} & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} R_{(1)}^T \\ r_{k+1}^T \end{bmatrix}, \quad (3-18)$$

其中 $r_{k+1} \in \mathbb{R}^{k+1}$ 是单位向量且与 $R_{(1)}$ 正交. 因此 Brand 更新给出:

$$Q^{(1)} = QQ_{(1)}, \quad (3-19)$$

$$\Sigma^{(1)} = \Sigma_{(1)}, \quad (3-20)$$

$$R^{(1)} = \begin{bmatrix} R & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} R_{(1)} & r_{k+1} \end{bmatrix}. \quad (3-21)$$

接下来处理第二个快照 $u_{\ell+2}$. 由于 $p_2 = 0$, $u_{\ell+2}$ 位于 U_ℓ 的列空间中, 且由条件 (4.6) 可知 $u_{\ell+2}$ 也位于 $Q^{(1)}$ 的列空间中. 计算投影坐标:

$$d_2^{(1)} = (Q^{(1)})^T W u_{\ell+2} = (QQ_{(1)})^T W u_{\ell+2} = Q_{(1)}^T (Q^T W u_{\ell+2}) = Q_{(1)}^T d_2, \quad (3-22)$$

其中 $d_2 = Q^T W u_{\ell+2}$. 于是对 $U_{\ell+2} = [U_{\ell+1} \mid u_{\ell+2}]$ 再次应用 **Brand** 更新, 有:

$$U_{\ell+2} = Q^{(1)} \begin{bmatrix} \Sigma^{(1)} & d_2^{(1)} \end{bmatrix} \begin{bmatrix} R^{(1)} & 0 \\ 0 & 1 \end{bmatrix}^T. \quad (3-23)$$

令 $Y_2 = \begin{bmatrix} \Sigma^{(1)} & d_2^{(1)} \end{bmatrix} \in \mathbb{R}^{k \times (k+1)}$, 其薄 SVD 为 $Y_2 = Q_{(2)} \Sigma_{(2)} R_{(2)}^T$. 则类似地, **Brand** 更新得:

$$Q^{(2)} = Q^{(1)} Q_{(2)} = Q Q_{(1)} Q_{(2)}, \quad (3-24)$$

$$\Sigma^{(2)} = \Sigma_{(2)}, \quad (3-25)$$

$$R^{(2)} = \begin{bmatrix} R^{(1)} & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} R_{(2)} & r_{k+2} \end{bmatrix}. \quad (3-26)$$

将式(3-21)代入(3-26):

$$R^{(2)} = \left(\begin{bmatrix} R & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} R_{(1)} & r_{k+1} \end{bmatrix} \right) \text{ 扩展为零块} \quad (3-27)$$

$$= \begin{bmatrix} R & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} R_{(1)} & r_{k+1} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} R_{(2)} & r_{k+2} \end{bmatrix}. \quad (3-28)$$

利用分块矩阵恒等式 $\begin{bmatrix} A & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} B & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} AB & 0 \\ 0 & 1 \end{bmatrix}$ 以及 $\begin{bmatrix} R_{(1)} & r_{k+1} \end{bmatrix}$ 的正交性, 可化简为:

$$R^{(2)} = \begin{bmatrix} R & 0 \\ 0 & I_2 \end{bmatrix} \begin{bmatrix} R_{(1)} & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} R_{(2)} & r_{k+2} \end{bmatrix}. \quad (3-29)$$

现在, 我们证明 $M_2 = \begin{bmatrix} \Sigma & d_1 & d_2 \end{bmatrix}$ 的薄 SVD 恰好给出 $Q_{(1)} Q_{(2)}$ 和 $\begin{bmatrix} R_{(1)} & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} R_{(2)} & r_{k+2} \end{bmatrix}$. 事实上, 由 Y_1 的 SVD:

$$\begin{bmatrix} \Sigma & d_1 \end{bmatrix} = Q_{(1)} \Sigma_{(1)} R_{(1)}^T, \quad (3-30)$$

于是

$$M_2 = \begin{bmatrix} \Sigma & d_1 & d_2 \end{bmatrix} = \begin{bmatrix} Q_{(1)} \Sigma_{(1)} R_{(1)}^T & d_2 \end{bmatrix} \quad (3-31)$$

$$= Q_{(1)} \begin{bmatrix} \Sigma_{(1)} & Q_{(1)}^T d_2 \end{bmatrix} \begin{bmatrix} R_{(1)}^T & 0 \\ 0 & 1 \end{bmatrix}. \quad (3-32)$$

注意到 $Q_{(1)}^T d_2 = Q_{(1)}^T (Q^T W u_{\ell+2}) = d_2^{(1)}$, 且 $\begin{bmatrix} \Sigma_{(1)} & d_2^{(1)} \end{bmatrix} = Y_2 = Q_{(2)} \Sigma_{(2)} R_{(2)}^T$. 因此

$$M_2 = Q_{(1)} (Q_{(2)} \Sigma_{(2)} R_{(2)}^T) \begin{bmatrix} R_{(1)}^T & 0 \\ 0 & 1 \end{bmatrix} \quad (3-33)$$

$$= (Q_{(1)} Q_{(2)}) \Sigma_{(2)} \left(\begin{bmatrix} R_{(1)} & 0 \\ 0 & 1 \end{bmatrix} R_{(2)} \right)^T. \quad (3-34)$$

上式即为 M_2 的薄 SVD, 其中 $\hat{Q} = Q_{(1)} Q_{(2)}$, $\hat{\Sigma} = \Sigma_{(2)}$, $\hat{R} = \begin{bmatrix} R_{(1)} & 0 \\ 0 & 1 \end{bmatrix} R_{(2)}$ (注意 $R_{(2)}$ 是 $(k+1) \times k$ 矩阵, $\hat{R} \in \mathbb{R}^{(k+2) \times k}$, 但薄 SVD 右矩阵应为 $k \times (k+2)$? 需核对维度. 实际上 $M_2 \in \mathbb{R}^{k \times (k+2)}$, 其薄 SVD 为 $M_2 = \hat{Q} \hat{\Sigma} \hat{R}^T$, 其中 $\hat{Q} \in \mathbb{R}^{k \times k}$, $\hat{\Sigma} \in \mathbb{R}^{k \times k}$, $\hat{R} \in \mathbb{R}^{(k+2) \times k}$. 上述推导中 $\hat{R} = \begin{bmatrix} R_{(1)} & 0 \\ 0 & 1 \end{bmatrix} R_{(2)}$, 其尺寸为 $(k+2) \times k$, 正确.) 于是, 由式(3-24)、(3-25)知, 逐次 Brand 更新得到:

$$Q^{(2)} = Q \hat{Q}, \quad \Sigma^{(2)} = \hat{\Sigma}, \quad R^{(2)} = \begin{bmatrix} R & 0 \\ 0 & I_2 \end{bmatrix} \hat{R}, \quad (3-35)$$

与公式(3-16)完全一致. $\square$

定理 2 (一般累积更新). 设 $Q \Sigma R^T$ 为 U_ℓ 的 rank- k core SVD, 且 s 个连续新快照 $u_{\ell+1}, \dots, u_{\ell+s}$ 的加权残差均为零. 构造扩展矩阵

$$M_s = [\Sigma \mid Q^T W u_{\ell+1} \mid Q^T W u_{\ell+2} \mid \cdots \mid Q^T W u_{\ell+s}] \in \mathbb{R}^{k \times (k+s)}, \quad (3-36)$$

并令 $M_s = \tilde{Q} \tilde{\Sigma} \tilde{R}^T$ 为其薄 SVD. 则一步更新

$$Q \leftarrow Q \tilde{Q}, \quad \Sigma \leftarrow \tilde{\Sigma}, \quad R \leftarrow \begin{bmatrix} R & 0 \\ 0 & I_s \end{bmatrix} \tilde{R} \quad (3-37)$$

给出的分解与逐次应用 Brand 更新完全相同, 且 $\tilde{Q}, \tilde{R}$ 数值正交.

证明: 对 s 进行归纳. $s = 1$ 时, $M_1 = \begin{bmatrix} \Sigma & d_1 \end{bmatrix}$, 其薄 SVD 给出 $\tilde{Q} = Q_{(1)}$, $\tilde{\Sigma} = \Sigma_{(1)}$,

$\tilde{R} = R_{(1)}$, 则更新(3-37)变为 $Q \leftarrow Q Q_{(1)}$, $\Sigma \leftarrow \Sigma_{(1)}$, $R \leftarrow \begin{bmatrix} R & 0 \\ 0 & 1 \end{bmatrix} R_{(1)}$, 这正是

Brand 更新 (零残差情况) 的结果.

假设对 $s-1$ 个快照结论成立. 考虑 s 个快照 $u_{\ell+1}, \dots, u_{\ell+s}$. 定义 $M_{s-1} = \begin{bmatrix} \Sigma & d_1 & \dots & d_{s-1} \end{bmatrix}$, 其薄 SVD 为 $M_{s-1} = \hat{Q}_{s-1} \hat{\Sigma}_{s-1} \hat{R}_{s-1}^T$. 由归纳假设, 经过前 $s-1$ 步 Brand 更新后:

$$Q^{(s-1)} = Q \hat{Q}_{s-1}, \quad \Sigma^{(s-1)} = \hat{\Sigma}_{s-1}, \quad R^{(s-1)} = \begin{bmatrix} R & 0 \\ 0 & I_{s-1} \end{bmatrix} \hat{R}_{s-1}. \quad (3-38)$$

现在处理第 s 个快照 $u_{\ell+s}$. 由于 $p_s = 0$, 有 $u_{\ell+s} = Q d_s$, 且由正交性可得 $u_{\ell+s} = Q^{(s-1)} d_s^{(s-1)}$, 其中 $d_s^{(s-1)} = (Q^{(s-1)})^T W u_{\ell+s} = \hat{Q}_{s-1}^T d_s$. 应用 Brand 更新:

$$Q^{(s)} = Q^{(s-1)} Q_{(s)} = Q \hat{Q}_{s-1} Q_{(s)}, \quad (3-39)$$

$$\Sigma^{(s)} = \Sigma_{(s)}, \quad (3-40)$$

$$R^{(s)} = \begin{bmatrix} R^{(s-1)} & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} R_{(s)} & r_{k+s} \end{bmatrix}. \quad (3-41)$$

其中 $Y_s = \begin{bmatrix} \Sigma^{(s-1)} & d_s^{(s-1)} \end{bmatrix}$ 的薄 SVD 为 $Y_s = Q_{(s)} \Sigma_{(s)} R_{(s)}^T$, r_{k+s} 是正交补向量.

另一方面, 构造 $M_s = \begin{bmatrix} M_{s-1} & d_s \end{bmatrix}$. 利用归纳假设的分解:

$$M_s = \begin{bmatrix} \hat{Q}_{s-1} \hat{\Sigma}_{s-1} \hat{R}_{s-1}^T & d_s \end{bmatrix} \quad (3-42)$$

$$= \hat{Q}_{s-1} \begin{bmatrix} \hat{\Sigma}_{s-1} & \hat{Q}_{s-1}^T d_s \end{bmatrix} \begin{bmatrix} \hat{R}_{s-1}^T & 0 \\ 0 & 1 \end{bmatrix} \quad (3-43)$$

$$= \hat{Q}_{s-1} \begin{bmatrix} \hat{\Sigma}_{s-1} & d_s^{(s-1)} \end{bmatrix} \begin{bmatrix} \hat{R}_{s-1}^T & 0 \\ 0 & 1 \end{bmatrix}. \quad (3-44)$$

而 $\begin{bmatrix} \hat{\Sigma}_{s-1} & d_s^{(s-1)} \end{bmatrix} = Y_s = Q_{(s)} \Sigma_{(s)} R_{(s)}^T$, 代入得:

$$M_s = \hat{Q}_{s-1} Q_{(s)} \Sigma_{(s)} R_{(s)}^T \begin{bmatrix} \hat{R}_{s-1}^T & 0 \\ 0 & 1 \end{bmatrix} \quad (3-45)$$

$$= \left(\hat{Q}_{s-1} Q_{(s)} \right) \Sigma_{(s)} \left(\begin{bmatrix} \hat{R}_{s-1}^T & 0 \\ 0 & 1 \end{bmatrix} R_{(s)} \right)^T. \quad (3-46)$$

因此 M_s 的薄 SVD 为 $\tilde{Q} = \hat{Q}_{s-1} Q_{(s)}$, $\tilde{\Sigma} = \Sigma_{(s)}$, $\tilde{R} = \begin{bmatrix} \hat{R}_{s-1} & 0 \\ 0 & 1 \end{bmatrix} R_{(s)}$. 于是

$$Q^{(s)} = Q\tilde{Q}, \quad (3-47)$$

$$\Sigma^{(s)} = \tilde{\Sigma}, \quad (3-48)$$

$$R^{(s)} = \begin{bmatrix} R & 0 \\ 0 & I_{s-1} \end{bmatrix} \hat{R}_{s-1} \text{ 经扩展} = \begin{bmatrix} R & 0 \\ 0 & I_s \end{bmatrix} \tilde{R}, \quad (3-49)$$

其中最后一步利用了 $\begin{bmatrix} R & 0 \\ 0 & I_{s-1} \end{bmatrix} \begin{bmatrix} \hat{R}_{s-1} & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} R & 0 \\ 0 & I_s \end{bmatrix} \tilde{R}$ 的块结构. 这就完成了归纳证明. $\square$

该定理的核心意义在于: 通过将 s 步更新凝聚为一次对扩展矩阵 M_s 的 SVD, 彻底避免了小正交矩阵 $Q_{(j)}$ 的连乘, 从而从根源上消除了正交性侵蚀. 由于 $\tilde{Q}$ 直接由 SVD 产生, 其数值正交性由算法保证, 无需任何额外重正交化.

3.3 复杂度分析

设 N 为快照维数 (有限元自由度), n 为总快照数, r 为截断秩 ($r \ll N$). 批次 SVD 的复杂度为 $\mathcal{O}(Nn^2)^{[7]}$; 经典 Brand ISVD 每次更新需 $\mathcal{O}(Nr)$ 计算投影及 $\mathcal{O}(r^3)$ 的小矩阵 SVD, 总复杂度 $\mathcal{O}(Nnr + nr^3)$. Zhang 改进算法消除了内部重正交化开销, 并将右空间更新优化为 $\mathcal{O}(nr^2)$, 因此整体复杂度仍为 $\mathcal{O}(Nnr)$, 但常数因子显著降低. 内存占用从批次模式的 $\mathcal{O}(Nn)$ 降至 $\mathcal{O}((N+n)r)$, 与总样本数 n 解耦, 实现了真正的流式处理.

4 Many-Query PDE 求解中采用 ISVD 的完整流程

为了清晰展示增量 SVD 在参数化 PDE 降阶求解中的完整角色, 本节从数据流和算法结构两个角度说明离线构基与在线求解的全过程.

4.1 整体流程概述

以下步骤概括了从参数化 PDE 到降阶近似解的主要流程.

离线阶段 (Offline)

1. 参数化椭圆 PDE: $A(\mu)u = f$.
2. 高精度有限元求解, 生成快照 $u_h(\mu_i), i = 1, \dots, n$.
3. 快照按列逐步到达, 使用 **Zhang 改进增量 core SVD** 更新分解 $U_\ell = Q\Sigma R^T$ (无需存储全量快照矩阵 U).
4. 提取前 r 个主成分作为 POD/RB 基: $V_r = Q(:, 1:r)$.

在线阶段 (Online)

5. 对新参数 μ , 将原系统投影到低维子空间:

$$V_r^T A(\mu) V_r a(\mu) = V_r^T f(\mu).$$

6. 求解低维系统得到系数 $a(\mu)$, 恢复近似解 $u_r(\mu) = V_r a(\mu)$.

4.2 增量 SVD 在离线构基中的核心作用

在传统的批次方法中, 离线阶段的第 3 步需要使用所有快照一次性构造快照矩阵并执行完整 SVD, 导致:

1. 内存峰值随快照数量 n 线性增长;
2. 每次新增快照后若需重新分解, 计算量呈平方增长.

采用增量 SVD 后, 这一过程变为流式处理:

维护当前的低秩分解 (Q, Σ, R) , 每次只处理一个新快照 $u_{\ell+1}$;

更新仅涉及对 $(k+1) \times (k+1)$ 的小矩阵 $Y = \begin{bmatrix} \Sigma & Q^T W u_{\ell+1} \\ 0 & p \end{bmatrix}$ 做 SVD;

通过 Zhang 改进的累积更新策略 (式 (3-37)), 避免了小正交矩阵的连乘, 正交性得以长期保持;

无需存储历史快照, 内存占用 $\mathcal{O}(Nr)$ 与 n 无关.

不同构基方法的复杂度和内存对比如表 4.1 所示, 清晰展示了增量 SVD 的优势.

表 4.1: 不同构基方法的复杂度和内存对比

方法	时间复杂度	峰值内存	是否流式
Batch SVD	$\mathcal{O}(Nn^2)^1$	$\mathcal{O}(Nn)$	否
Brand ISVD (经典)	$\mathcal{O}(Nnr)$	$\mathcal{O}((N+n)r)$	是
Zhang ISVD (改进)	$\mathcal{O}(Nnr)$	$\mathcal{O}((N+n)r)$	是

5 数值实验与性能分析

为了全面评估 Zhang 改进增量 SVD 算法在参数化 PDE 降阶中的实际表现^[6], 本节设计了三个层次的数值实验, 分别对应算法基准测试、低维问题验证和高维大尺度考核.

算法基准测试: 在流式矩阵生成场景下, 验证改进 ISVD 的加权正交性保持能力与分解正确性.

1D 参数化 PDE: 对比批次 SVD、经典 Brand ISVD 和 Zhang ISVD 在离线构基时间、累计误差和正交性演化上的差异.

2D 大规模 PDE: 在更高维度的有限元网格上, 测量峰值内存压缩比、离线时间加速比以及降阶模型的求解精度.


所有实验均在有限元框架下进行, 加权内积矩阵 W 取为质量矩阵 $M^{[3]}$ (2D 问题中网格规模适当缩小以保证可计算性).

5.1 增量 SVD 算法基准测试

5.1.1 正交性演化

首先, 在纯矩阵流式更新场景下, 测试 Zhang 改进 ISVD 的加权正交性误差 $\mathcal{E}_W(Q) = \|I - Q^T W Q\|_F$. 图 5.1 展示了随着快照数量增加, 左奇异矩阵 Q 的加权正交性误差的变化情况.

¹此处假定 $N \geq n$; 更一般地, Batch SVD 复杂度为 $\mathcal{O}(Nn \min(N, n))$.


 图 5.1: 加权正交性误差 $\mathcal{E}_W(Q)$ 随更新步数的变化 ($W = M$)

可见, 在整个 500 次更新过程中, $\mathcal{E}_W(Q)$ 始终维持在 10^{-15} 量级 (机器精度附近), 未出现累积发散. 这说明累积更新策略 (式 (3-37)) 从根本上避免了小正交矩阵连乘带来的误差放大^[5-6].

5.1.2 分解正确性验证

构造一个简单的二维椭圆方程 (系数 $a = 1$, 源项 $f = 1$, 网格尺寸 0.1, 有限元阶数 2) 验证改进 ISVD 输出分解的正确性. 图 5.2 展示了有限元解在网格点上的分布.




图 5.2: 简单二维椭圆方程的有限元解分布

进一步观察增量更新过程中核心矩阵的奇异值分布 (图 5.3), 绝大多数奇异值处于 10^{-15} 量级, 表明数值秩已被有效控制, 从侧面验证了改进 ISVD 的数值稳定性.




图 5.3: 核心矩阵的奇异值分布（对数坐标）

5.2 1D 参数化 PDE 实验

考虑一维变系数椭圆方程：

$$-\frac{d}{dx}\left((1+\mu x)\frac{du}{dx}\right) = 1, \quad x \in (0, 1), \quad u(0) = u(1) = 0,$$

参数 $\mu \in [0, 1]$, 等距取 200 个训练参数, 100 个测试参数. 有限元离散单元数 $N = 500$.

5.2.1 离线构基时间对比

图 5.4 给出了批次 SVD 与经典 Brand ISVD 的累计时间随快照数增长的变化, 以及 Brand ISVD 的矩阵正交性误差 $\mathcal{E}_W(Q)$ 的演化.




图 5.4: 1D 问题累计离线时间对比

批次 SVD 的累计时间随快照数呈二次增长 ($\mathcal{O}(n^2)$)^[7]; 而经典 Brand ISVD 的累计时间增长更快, 其原因包括截断秩设置过小及 Python SVD 库的小矩阵开销. 尤为值得注意的是, 400 次更新后 Brand ISVD 的加权正交性误差 $\mathcal{E}_W(Q)$ 急剧上升至 10^1 量级, 导致数值不稳定, 后续更新需花费更多时间处理误差^[5].

5.2.2 正交性对比

图 5.5 展示了 Zhang 改进 ISVD 在运行过程中加权正交性误差的变化, 同时以批次 SVD 的正交性 (恒为机器精度) 作为基准.




图 5.5: Zhang 改进 ISVD 的加权正交性误差

可以看到, Zhang 改进 ISVD 在整个 550 次更新中 $\mathcal{E}_W(Q)$ 始终保持在 10^{-3} 以下, 远优于经典 Brand ISVD 在 400 步后的完全发散. 10^{-3} 的误差是算法为换取极高效率而主动付出的轻微代价, 在实际降阶应用中仍可接受.

5.2.3 单步时间差分析

图 5.6 给出了每次迭代中批次 SVD 与 Zhang ISVD 的单步时间差及二次拟合曲线.




图 5.6: 单步时间差随快照数的变化（批次 SVD 减增量 SVD）

拟合曲线为 $3.20 \times 10^{-8}k^2 - 3.75 \times 10^{-5}k + 2.81 \times 10^{-4}$. 这里的 k 是当前快照数. 可以看出, 单步时间差呈现二次增长趋势, 且在截断误差取机器误差时增量 SVD 的效率优势不明显. 所以在下面的 2D 大规模 PDE 实验中, 我们将适当放宽截断误差要求, 以更明显地展示增量 SVD 在大规模问题中的效率优势.

5.3 基于两个参数的大规模 PDE 实验

将模型简化为仅含线性依赖的扩散系数:

$$-\nabla \cdot ((1 + \mu_1 x + \mu_2 y) \nabla u) = 1, \quad (x, y) \in (0, 1)^2,$$

齐次 Dirichlet 边界条件. 采用相同的 40×40 网格 ($N = 1600$), 总快照数 $n = 50000$, 截断秩根据奇异值阈值动态选择. 参数 μ_1, μ_2 在 $[-0.2, 0.2]$ 内均匀采样.

图 5.7 展示了 Batch SVD 与 Zhang 增量 SVD 在该简化模型上的性能对比.




图 5.7: 无交叉项模型下 Batch SVD 与增量 SVD 的性能对比

内存压缩效果：与三个参数的模型类似, Batch POD 需要存储全部快照, 峰值内存随快照数线性增长, 当 $n = 50\,000$ 时达到约 1240 MB. 而增量 SVD 仅维护低维分解因子, 峰值内存稳定在 10 MB 左右, 压缩比超过 120 倍, 存储节约率超过 99%.

离线时间对比：Batch SVD 的累计时间相对较高, 而增量 SVD 的累计时间近似线性 (约 8 秒), 流式更新策略显著降低了重复计算成本.

数值解验证：二者的误差几乎相差无异, 均在 10^{-2} 量级, 说明增量 SVD 在保持数值稳定的同时, 能够高效逼近最优低维子空间.

5.4 基于三个参数的大规模 PDE 实验

将模型扩展至二维单位正方形区域:

$$-\nabla \cdot ((1 + \mu_1 x + \mu_2 y + \mu_3 xy) \nabla u) = 1, \quad (x, y) \in (0, 1)^2,$$

齐次 Dirichlet 边界条件. 采用 40×40 的网格剖分, 自由度 $N = 1600$, 总快照数 $n = 50\,000$, 截断秩根据奇异值阈值动态选择.




图 5.8: Batch SVD 与增量 SVD 的性能对比：累计时间、峰值内存及重建误差随快照数的变化

离线时间对比：与之前两个参数的大规模 PDE 结果相仿, Batch POD 的累计时间随快照数呈超线性增长（最终为 12.39 秒），这是由于每次完整 SVD 的代价随矩阵规模增大而急剧增加。相比之下, Zhang ISVD 的累计时间近似线性增长（最终为 8.43 秒），其增量更新策略避免了重复处理历史数据。尽管在快照数较小时增量 SVD 的单块开销略高,但随着数据量增大,其流式计算的优势愈发明显。

内存压缩效果：这里和两个参数的实验相差不大。Batch POD 需要同时存储所有历史快照,当快照数达到 50000 时,峰值内存高达 1240.3 MB（存储整个快照矩阵）。而 Zhang ISVD 采用流式处理,仅保留低维分解因子 (Q, Σ, R),峰值内存稳定在 10.3 MB,压缩比达到 120 倍。即使与完整存储所有快照的 Batch POD 相比,增量方法的存储节约率也达到 99.17%,充分体现了其在大规模快照数据下的内存优势。

数值解验证：图 5.8 中的误差子图展示了两种方法重建快照矩阵的相对误差。Batch POD 的重建误差稳定在约 2.1×10^{-7} ,而 Zhang ISVD 的误差从初始的 2.00×10^{-7} 的机器误差变化到 6.77×10^{-2} ,之后迅速下降,最终收敛到 1.47×10^{-5} 。这表明增量 SVD 在流式处理过程中能够高效逼近最优低维子空间,且最终精度满足工程需求。若需要与高精度有限元解进行点对点对比,以测试参数 $\mu = 0.5$ 为例,降阶解的最大相对误差约为 10^{-5} 量级,说明截断后的低维基足以捕捉主导物理特征^[1-2]。

6 结论与未来展望

6.1 结论

通过一维和二维参数化椭圆型方程的数值实验,我们对增量奇异值分解在缩减基构造中的表现有了一些认识.

先看数值稳定性,实验中发现,它确实避免了 Brand 算法随着更新步数增加正交性变差的问题.不过有意思的是,在二维大规模算例中,增量 SVD 的最终重建误差稳定在 1.5×10^{-5} 左右,而批处理 SVD 可以做到 2.1×10^{-7} .两者差了两个数量级.虽然对于工程问题这个精度通常够用了(比如 10^{-5} 对解场来说已经很不错),但这个差距还是值得注意的.增量方法的初始误差一度跳到 6.77×10^{-2} ,随着快照增加才慢慢降下来.这说明刚起步的几块数据质量对整体影响比较大.

内存方面的收益非常明显.在 40×40 网格、五万快照的设定下,普通批处理 SVD 要存下整个快照矩阵,峰值内存跑到 1240.3MB.增量 SVD 只需要维护低维分解因子,稳定在 10.3MB,压缩比超过 120 倍,节省了 99% 以上的内存.这意味着即使快照数量再翻几倍,内存也不至于成为瓶颈.

计算时间上,批处理 SVD 累计花了 12.39 秒,增量 SVD 是 8.43 秒,快了大概三分之一.而且增量 SVD 基本是线性增长.虽然处理小块数据时增量 SVD 的单块开销比批处理高一点,但快照一多,流式更新的好处就显现出来了.

总的来说,对于快照量很大的离线构基任务,增量 SVD 在内存、时间、精度之间找到了一个很实用的平衡点,尤其是在内存受限的场景下,它比传统的批处理 SVD 更合用.

6.2 未来展望

尽管增量 SVD 在数值实验中表现出良好的性能,仍有若干理论问题需要进一步澄清.首先,精度损失的内在机理尚不明确.增量 SVD 的最终重建误差收敛至 10^{-5} 量级,而批处理 SVD 可达 10^{-7} ,两者之间存在约两个数量级的差距.这一误差的来源需从累积更新过程的各个环节加以分析,特别是投影残差、QR 分解以及局部 SVD 截断对整体精度的影响.此外,块大小与截断阈值对误差的定量影响关系尚未建立.若能从理论上推导出误差的上界,将为实际应用中的参数选择

提供重要依据.

其次,当前实验仅覆盖了自由度 $N = 1600$ 、快照数 $n = 50\,000$ 的规模.对于真实工程问题,如三维非定常流动或全阶模型自由度达数十万乃至上百万、快照数达百万量级的场景,增量 SVD 的可扩展性仍需验证.具体而言,需要考察其在超大规模下是否仍能保持近似线性的计算时间增长,以及是否能够在分布式内存或磁盘流式存储的条件下高效运行.

另外,现有算法采用固定的块大小和固定的截断阈值,缺乏自适应性.未来可探索根据新快照与当前低维子空间之间的残差范数动态调整更新频率,或根据奇异值谱的衰减速率自动选择截断精度.这种自适应策略有望在计算开销与近似精度之间实现更优的权衡.

最后,增量 SVD 可与更完整的模型降阶流程深度集成.例如,将其与贪婪采样方法或在线后验误差估计器相结合,实现“边采样边构基”的完全在线离线构基模式.这一方向有望进一步提升 many-query 场景下的整体计算效率.

综上所述,增量 SVD 在工程降阶中的应用仍有诸多值得深入研究的理论缺口与技术细节.填补这些空白,将有助于将其从一种启发式算法发展为具有严格理论保证且适用于大规模计算的标准工具.

7 参考文献

- [1] HESTHAVEN J S, ROZZA G, STAMM B Certified Reduced Basis Methods for Parametrized Partial Differential Equations. Springer, 2015.
- [2] PATERA A T ROZZA G Reduced Basis Approximation and A Posteriori Error Estimation for Parametrized Partial Differential Equations. MIT Pappalardo Graduate Monographs in Mechanical Engineering, 2007.
- [3] FAREED H, SINGLER J R, ZHANG Y, Incremental Proper Orthogonal Decomposition for PDE Simulation Data. Computers & Mathematics with Applications, 2018, 75(6): 1942-1960.
- [4] BRAND M. Incremental Singular Value Decomposition of Uncertain Data with Missing Values//European Conference on Computer Vision (ECCV). Springer, 2002: 707-720.
- [5] BRAND M. Fast Low-Rank Modifications of the Thin Singular Value Decomposition. Linear Algebra and its Applications, 2006, 415(1): 20-30.
- [6] ZHANG Y. An Answer to an Open Question in the Incremental SVD. Numerical Linear Algebra with Applications, 2022, 29(6): e2448.
- [7] GOLUB G H LOAN C F V Matrix Computations. 4th ed. Johns Hopkins University Press, 2013.

附录：Incremental SVD 核心更新模块代码实现

以下为本论文中基于张量分块理论实现的 Incremental SVD 核心更新模块代码片段（Python 实现）：

```
import numpy as np

class IncrementalSVD_Zhang2022:
    def __init__(self, W=None, tol=1e-10, reorth_tol=1e-10,
                 truncate=True):
        self.W = W
        self.tol = tol
        self.reorth_tol = reorth_tol
        self.truncate = truncate
        self.Q = None
        self.s = None
        self.R = None
        self.V_list = []
        self.Q0 = None # 内部旋转累积矩阵
        self.q = 0      # 延迟计数
        self.m = None

    def _Wmv(self, x):
        return x if self.W is None else self.W @ x

    def _Wnorm(self, x):
        return np.sqrt(max(0, np.dot(x.T.flatten(), self._Wmv(x).
                                     flatten()))))

    def update(self, u):
        u = u.reshape(-1, 1)
```

```
if self.Q is None:
    # Algorithm 1: Initialization
    p = self._Wnorm(u)
    self.s = np.array([p])
    self.Q = u / p
    self.R = np.array([[1.0]])
    self.Q0 = np.eye(1)
    self.m = u.size
    self.q = 1
    return self

# 1. 投影与残差计算
d = self.Q.T @ self._Wmv(u)
e = u - self.Q @ d
p = self._Wnorm(e)

# 2. 处理线性相关列 (Algorithm 10, Line 2)
if p < self.tol:
    self.q += 1
    self.V_list.append(d)
    return self

# 3. 秩增加更新前, 首先刷新延迟列 (Algorithm 10, Lines
6-12)
if len(self.V_list) > 0:
    V_mat = np.column_stack(self.V_list)
    Y_deferred = np.column_stack([np.diag(self.s), V_mat])
    Uy, sy, Vty = np.linalg.svd(Y_deferred, full_matrices=
False)
```

```

# 更新基旋转和奇异值
self.Q = self.Q @ (self.Q0 @ Uy)
self.s = sy
self.Q0 = np.eye(self.s.size)

# 更新 R
k_old = Uy.shape[0]
self.R = np.vstack([self.R @ Vty.T[:k_old, :], Vty.T[
k_old:, :]])

# 重新计算投影 d
d = self.Q.T @ self._Wmv(u)
self.V_list = []
self.q = 0

# 4. 执行秩增加更新 (Algorithm 10, Lines 13-25)
e_unit = e / p
# 增量重正交化: 仅针对新向量 e
if abs(np.dot(e_unit.T, self._Wmv(self.Q[:, [0]]))) > self.
reorth_tol:
    e_unit = e_unit - self.Q @ (self.Q.T @ self._Wmv(e_unit
))

    e_unit /= self._Wnorm(e_unit)

k = self.s.size
Y = np.zeros((k + 1, k + 1))
np.fill_diagonal(Y[:k, :k], self.s)
Y[:k, k] = d.flatten()
Y[k, k] = p

```

```

    Uy, sy, Vty = np.linalg.svd(Y, full_matrices=False)

    # 核心逻辑：应用 Q0 并重置 (Algorithm 10)
    temp_Q0 = np.eye(k + 1)
    temp_Q0[:k, :k] = self.Q0
    current_Q0 = temp_Q0 @ Uy

    if sy[-1] > self.tol or not self.truncate:
        self.Q = np.column_stack([self.Q, e_unit]) @ current_Q0
        self.s = sy
        R_ext = np.zeros((self.R.shape[0] + 1, k + 1))
        R_ext[:self.R.shape[0], :k] = self.R
        R_ext[-1, -1] = 1.0
        self.R = R_ext @ Vty.T
        self.Q0 = np.eye(k + 1)
    else:
        # 截断：仅保留前 k 个成分
        self.Q = np.column_stack([self.Q, e_unit]) @ current_Q0
       [:, :k]

        self.s = sy[:k]
        R_ext = np.zeros((self.R.shape[0] + 1, k + 1))
        R_ext[:self.R.shape[0], :k] = self.R
        R_ext[-1, -1] = 1.0
        self.R = R_ext @ Vty.T[:, :k]
        self.Q0 = np.eye(k)

    self.V_list = []
    self.q = 1
    return self

```

```

def finalize(self):
    """处理最后可能遗留的 V 缓存"""
    if len(self.V_list) > 0:
        V_mat = np.column_stack(self.V_list)
        Y = np.column_stack([np.diag(self.s), V_mat])
        Uy, sy, Vty = np.linalg.svd(Y, full_matrices=False)
        self.Q = self.Q @ (self.Q0 @ Uy)
        self.s = sy
        k_old = Uy.shape[0]
        self.R = np.vstack([self.R @ Vty.T[:k_old, :], Vty.T[
k_old:, :]])
    else:
        self.Q = self.Q @ self.Q0
        self.Q0 = np.eye(self.s.size)
    return self.Q, self.s, self.R

def orthogonality_error(self):
    if self.Q is None: return 0.0
    Q_eff = self.Q @ self.Q0
    G = Q_eff.T @ self._Wmv(Q_eff)
    return np.linalg.norm(np.eye(G.shape[0]) - G)

```


作者简历

基本信息

钱周越，男，浙江大学信息与计算科学专业，本科生。

学术与科研经历

- **Tree Imagine: 面向视觉空间规划的 LLM 幻觉纠正研究 (独立负责)** 2025.09 – 2026.01

针对大语言模型在逐步视觉空间规划任务中的“幻觉”问题，设计了基于 LLM 引导的树搜索框架，通过智能剪枝将搜索空间从指数级降至多项式级。创新性地提出了基于“反射”的迭代式幻觉纠正算法，通过动态修正动作空间，将长序列规划任务成功率提升约 40%。在多个视觉空间规划基准（如 FrozenLake、Where2Place）上对 Gemini 2.5 Flash 等前沿多模态大模型进行了系统性的基准测试。

- **MATLAB 曲线拟合工具箱的国产替代产品研发与应用 (项目立项人)** 2024.03 – 2025.03

负责在北太天元软件中复现 MATLAB CurveFitting 函数包。主导了基于 C++ 的代码架构设计，通过详尽的数学推导，完成了各类型样条（Spline）与线/非线性回归函数的原理验证及底层实现（包括 spapi, csape, ppmak 等），成功保证了算法性能指标。最终成果已由北太天元商业化发布。

工程与创业经历

- 幻域科技 (杭州) 有限公司 (联合创始人)

致力于自研 AI 模型的垂直领域微调与实际应用场景落地. 与浙江大学医学院、经济学院及信息中心深度合作，为校园录播平台建立个人笔记管理系统. 现已与成都华栖云科技有限公司合作推广，平台上线至今支持超 3000 节课程，服务超 10000 名在校师生.

• **“kick 工程”体育数据可视化平台 (核心主理人)**

结合底层代码开发与 CAD 技术，致力于足球领域赛事数据的可视化落地. 通过数据解析与图形化渲染，直观呈现进球的产生逻辑与战术细节. 目前已在 B 端与百度、B 站、懂球帝等头部平台达成切实合作，持续推动技术能力与内容的商业化拓展.

• **网易数智 - 数据科学产品实习生** 2024.06 – 2024.08

负责“浙商中拓 ChatBI”项目，深入挖掘业务场景需求，基于网易 AI 基座引导团队完成垂类模型微调与方案设计，最终成功达成 50 万元项目合同. 同时兼任团队数据分析助理，通过多维度数据分析辅助团队管理与业务决策.

• **浙江海控南科华铁数智科技股份有限公司 - 数据分析实习生** 2024.01 – 2024.03

参与“大黄蜂”客户数据处理，通过数据挖掘与分析成功识别高价值客群，优化产品策略，有效支持公司制定更精准的业务决策与策略实施.

荣誉奖项

- 2024–2025 学年：浙江省政府奖学金、浙江大学三等奖学金、学业优秀标兵
- 2023–2024 学年：浙江大学三等奖学金、学业优秀标兵
- 2023 年：浙江省数学竞赛三等奖、杭州亚运会“五星级志愿者”
- 2022–2023 学年：浙江大学优秀学生、文体/公益/创新创业/学业优秀等标兵称号

本科生毕业论文（设计）任务书

一、题目：

二、指导教师对毕业论文（设计）的进度安排及任务要求：

起讫日期 20 年 月 日 至 20 年 月 日

指导教师（签名）_____ 职称 _____

三、系或研究所审核意见：

负责人（签名）_____

年 月 日

本科生毕业论文（设计）考核

一、指导教师对毕业论文（设计）的评语：

指导教师（签名）_____

年 月 日

二、答辩小组对毕业论文（设计）的答辩评语及总评成绩：

成绩 比例	文献综述 (10%)	开题报告 (15%)	外文翻译 (5%)	毕业论文（设计）质量及答辩 (70%)	总评 成绩
分值	10	15	5	70	100

负责人（签名）_____

年 月 日

第二部分

毕业论文（设计）开题报告

浙江大学

本科生毕业论文

文献综述和开题报告



学生姓名	钱周越
学生学号	3220104074
指导教师	李雨文
年级与专业	2022级信息与计算科学
所在学院	数学科学学院

一、题目： 基于增量奇异值分解的参数化 PDE 降阶方法研究

二、指导教师对文献综述和开题报告的具体要求：

指导教师（签名） _____

年 月 日

一、文献综述

1 背景介绍

1.1 小节

1.2 小节

2 国内外研究现状

2.1 研究方向及进展

2.2 存在问题

3 研究展望

二、开题报告

1 问题提出的背景

正文格式与具体要求 `zjuthesisrules`

1.1 背景介绍

1.1.1 项目提出的原因

2 本研究的意义和目的

3 项目的主要内容和路线

3.1 主要研究内容

3.2 技术路线

3.3 可行性分析

4 研究计划进度安排及预期目标

4.1 进度安排

4.2 预期目标

三、外文翻译

摘要

1 节标题

四、外文原文

浙江大学本科毕业论文（设计）编写规则

为规范我校本科生毕业论文(设计)编写格式,根据《学位论文编写规则》(GB/T 7713.1-2006),结合我校实际情况,制定本本科生毕业论文(设计)编写规则。

1 本科生毕业论文（设计）工作文档

本科生毕业论文（设计）工作文档分两大部分。

第一部分（论文（设计）材料）编排顺序依次是前置部分、主体部分、结尾部分、《浙江大学本科毕业论文（设计）任务书》、《浙江大学本科毕业论文（设计）考核表》。

第二部分（开题材料）编排顺序依次是文献综述和开题报告封面、指导教师对文献综述和开题报告具体要求、目录、文献综述、开题报告、外文翻译和外文原文、《浙江大学本科文献综述和开题报告考核表》。

本科生毕业论文（设计）工作文档的纸质版，可作为院（系）教学资料存档保存，参照上述编排顺序，打印装订成册，其中封面、题名页、承诺书、致谢、摘要、《浙江大学本科毕业论文（设计）任务书》、《浙江大学本科毕业论文（设计）考核表》、指导教师对文献综述和开题报告具体要求、《浙江大学本科文献综述和开题报告考核表》应单面打印，其它部分内容应双面打印；主体部分各章之间应分页。论文检测报告、浙江大学本科毕业论文（设计）专家评阅意见、浙江大学本科毕业论文（设计）现场答辩记录表等文档可作为附件单面打印装订在最后面。

本科生毕业论文（设计）工作文档的电子版，其内容中应不包含指导性、评价性及绩效考核等内容，如：《浙江大学本科毕业论文（设计）任务书》、《浙江大学本科毕业论文（设计）考核表》、指导教师对文献综述和开题报告具体要求、《浙江大学本科文献综述和开题报告考核表》、论文检测报告、浙江大学本科毕业论文（设计）专家评阅意见、浙江大学本科毕业论文（设计）现场答辩记录表等。

1.1 前置部分

- (1) 封面
- (2) 题名页（可根据需要）
- (3) 承诺书
- (4) 勘误页(可根据需要)
- (5) 致谢
- (6) 摘要页

- (7) 序言或前言(可根据需要)
- (8) 目次页
- (9) 图和附表清单(可根据需要)
- (10) 符号、标志、缩略词、首字母缩写、计量单位、术语等的注释表(可根据需要)

1.2 主体部分

- (1) 引言(绪论)
- (2) 正文
- (3) 结论

1.3 结尾部分

- (1) 参考文献
- (2) 附录(可根据需要)
- (3) 分类索引、关键词索引(可根据需要)
- (4) 作者简历

2 编写规范与要求

2.1 语种要求

论文撰写语种,对于国际学生,参照 2017 年教育部、外交部、公安部联发的第 42 号令《学校招收和培养国际学生管理办法》执行;非国际学生遵照国家相关法律法规执行。

2.2 前置部分

2.2.1 封面

作者学号: 全日制学生需要填写学号。

论文题目: 应准确概括整个论文的核心内容,简明扼要,一般不能超过 25 个汉字,英文题目翻译应简短准确,一般不应超过 150 个字母,必要时可以加副标题。

2.2.2 承诺书

见浙江大学本科生毕业论文(设计)承诺书。

2.2.3 致谢

致谢对象限于对课题工作、毕业论文(设计)完成等方面有较重要帮助的人员。

2.2.4 摘要

包括中文摘要和英文摘要两部分。摘要应具有独立性和自含性,即不阅读论文全文就能获得必要信息。摘要的内容应包含与论文等量的主要信息,供读者确定有无必要阅读

全文，也可供二次文献采用。摘要应说明研究目的、方法、结果和结论等，重点是结果和结论。不宜使用图、表、化学结构式、非公知公用的符号和术语。中文摘要的字数一般为300-600字以内，英文摘要实词在300个左右。英文摘要应与中文摘要内容相对应。摘要最后另起一行，列出3-8个关键词。关键词应体现论文特色，具有语义性，在论文中有明确的出处，并应尽量采用《汉语主题词表》或各专业主题词表提供的规范词。

2.2.5 序言或前言

毕业论文（设计）的序言或前言，一般是作者对本篇论文基本特征的简介，如说明研究工作缘起、背景、主旨、目的、意义、编写体例，以及资助、支持、协作经过等。这些内容也可在正文引言中说明。

2.2.6 目次页

论文中内容标题的集合。

2.2.7 图和附表清单

论文中如图表较多，可以分别列出清单置于目次页之后。图的清单应有序号、图题和页码。表的清单应有序号、表题和页码。

2.2.8 符号、标志、缩略词、首字母缩写、计量单位、术语等的注释表。

2.3 主体部分

包括引言（绪论）、正文和结论。

2.3.1 一般要求

2.3.1.1 引言（绪论）

应包括论文的研究目的、流程和方法等。论文研究领域的历史回顾、文献回溯、理论分析等内容，应独立成章，用足够的文字叙述。

2.3.1.2 正文

主体部分由于涉及不同的学科，在选题、研究方法、结果表达方式等有很大的差异，不能作统一的规定。但是，必须实事求是、客观真切、准备完备、合乎逻辑、层次分明、简练可读。

图：图包括曲线图、构造图、示意图、框图、流程图、记录图、地图、照片等。图应具有“自明性”；图宜有图题，即名称，置于图的编号后。图的编号和图题置于图下方；照片图要求主题和主要显示部分的轮廓鲜明，便于制版。如用放大缩小的复制品，必须清晰，反差适中。照片上应有表示目的物尺寸的标度。

表：表应具有“自明性”。表宜有表题，即表的名称，置于表的编号之后。表的编号和表题应置于表上方。表的编排，一般是内容和测试项目由左至右横读，数据依序竖读。

毕业论文（设计）文献综述和开题报告考核

导师对开题报告、外文翻译和文献综述的评语及成绩评定：

成绩比例	文献综述 (10%)	开题报告 (15%)	外文翻译 (5%)
分值	10	15	5

导师签名 _____

年 月 日

学院盲审专家对开题报告、外文翻译和文献综述的评语及成绩评定：

成绩比例	文献综述 (10%)	开题报告 (15%)	外文翻译 (5%)
分值			

开题报告审核负责人（签名/签章） _____

年 月 日