

基于增量奇异值分解的参数化 PDE 降阶方法研究

钱周越
指导老师：李雨文

数学科学学院
浙江大学

2026 年 5 月 22 日

目录

目录

研究背景与动机

经典增量 SVD 及其正交性问题

改进算法原理

数值实验

结论与展望

参考文献

研究背景与动机



参数化椭圆方程与 many-query 场景

考虑含参数的一族椭圆型方程：

$$-\nabla \cdot (a(x; \mu) \nabla u(x; \mu)) = f(x), \quad x \in \Omega, \mu \in \mathcal{P} \subset \mathbb{R}^p.$$

有限元离散后得到大规模线性系统：

$$A(\mu)u_h(\mu) = f(\mu), \quad A(\mu) \in \mathbb{R}^{N \times N}, u_h(\mu) \in \mathbb{R}^N, N \gg 1.$$

- 参数 μ 改变 $\Rightarrow$ 需反复求解不同的 $A(\mu)u = f$
- 高精度 FEM 解昂贵，重复求解成本不可接受
- 目标：在保证精度的前提下显著降低多参数重复求解开销

缩减基方法 (RB): 离线/在线分解

核心思想: 用低维子空间逼近高维有限元解

$$u_h(\mu) \approx V_r a(\mu), \quad V_r \in \mathbb{R}^{N \times r}, \quad r \ll N.$$

Galerkin 投影到 V_r :

$$V_r^T A(\mu) V_r a(\mu) = V_r^T f(\mu),$$

在线阶段仅需解 $r \times r$ 系统.

- 离线阶段: 构造缩减基 V_r (主要计算瓶颈)
- 在线阶段: 快速求解并恢复 $u_r(\mu) = V_r a(\mu)$

POD/SVD: 最优低秩子空间与“快照矩阵”

收集 m 个参数样本对应的 FEM 快照:

$$U = [u_h(\mu_1), \dots, u_h(\mu_m)] \in \mathbb{R}^{N \times m}.$$

做 SVD (或加权 core SVD) 得到 POD 基:

$$U = \Phi \Sigma \Psi^T, \quad V_r := \Phi_{(:,1:r)}.$$

截断误差 (Frobenius 范数意义下的最优性):

$$\|U - U_r\|_F^2 = \sum_{i>r} \sigma_i^2, \quad U_r = \Phi_r \Sigma_r \Psi_r^T.$$

批处理 SVD 的三大瓶颈:

- ① 计算复杂度 $\mathcal{O}(Nm^2)$
- ② 内存峰值 $\mathcal{O}(Nm)$
- ③ 无法流式处理

经典增量 SVD 及其正交性问题

加权 Core SVD 框架

由于快照来自有限元离散，自然内积为加权形式（质量矩阵 $W = M$ ）：

$$\langle u, v \rangle_W = u^T W v.$$

Core SVD 分解：

$$U = Q \Sigma R^T, \quad Q^T W Q = I, \quad R^T R = I,$$

其中 $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $\sigma_1 \geq \dots \geq \sigma_r > 0$.

Brand 经典增量 SVD 算法

已知 $U_\ell = Q\Sigma R^T$ (rank- k core SVD), 新快照 $u_{\ell+1}$:

① 投影与加权残差:

$$d = Q^T(Wu_{\ell+1}), \quad e = u_{\ell+1} - Qd, \quad p = \sqrt{e^T W e}.$$

② 构造小矩阵 $Y = \begin{bmatrix} \Sigma & d \\ 0 & p \end{bmatrix} \in \mathbb{R}^{(k+1) \times (k+1)}$, 计算 SVD: $Y = Q_Y \Sigma_Y R_Y^T$.

③ 更新分解:

$$Q \leftarrow [Q \mid \tilde{e}] Q_Y, \quad \Sigma \leftarrow \Sigma_Y, \quad R \leftarrow \begin{bmatrix} R & 0 \\ 0 & 1 \end{bmatrix} R_Y.$$

优势: 单步复杂度 $\mathcal{O}(k^3)$, 远低于重算全矩阵.

经典算法的正交性退化问题

Brand 算法中 $Q \leftarrow [Q \mid \tilde{e}]Q_Y$ 涉及小正交矩阵 Q_Y 的连乘:

$$Q \leftarrow Q \prod Q_Y^{(i)}.$$

在有限精度下, 连乘累积舍入误差导致 $Q^T W Q$ 严重偏离单位矩阵.

Brand (2006) 指出的开放问题

“为了保证一定的整体数值精度水平, 需要多久进行一次重正交化是一个开放问题; 这不会改变整体复杂度.”

传统重正交化计算开销巨大, 尤其在加权内积下.

改进算法原理



Zhang (2022) 改进算法的核心思想

通过累积更新策略, 将 s 步更新凝聚为一次对扩展矩阵的 SVD, 彻底避免小正交矩阵连乘.

定理 (累积更新): 设 $Q\Sigma R^T$ 为 U_ℓ 的 rank- k core SVD, s 个连续新快照的加权残差均为零. 构造

$$M_s = [\Sigma \mid Q^T W u_{\ell+1} \mid \cdots \mid Q^T W u_{\ell+s}] \in \mathbb{R}^{k \times (k+s)},$$

并令 $M_s = \hat{Q}\hat{\Sigma}\hat{R}^T$ 为其薄 SVD. 则一步更新

$$Q \leftarrow Q\hat{Q}, \quad \Sigma \leftarrow \hat{\Sigma}, \quad R \leftarrow \begin{bmatrix} R & 0 \\ 0 & I_s \end{bmatrix} \hat{R}$$

与逐次应用 Brand 更新完全等价, 且 $\hat{Q}, \hat{R}$ 数值正交.

算法优势与复杂度对比

Table: 不同构基方法的复杂度和内存对比

方法	时间复杂度	峰值内存	流式处理
Batch SVD	$\mathcal{O}(Nn^2)$	$\mathcal{O}(Nn)$	否
Brand ISVD (经典)	$\mathcal{O}(Nnr)$	$\mathcal{O}((N+n)r)$	是
Zhang ISVD (改进)	$\mathcal{O}(Nnr)$	$\mathcal{O}((N+n)r)$	是

- **数值稳定性**: 从根源上消除了正交性退化, 无需重正交化
- **内存效率**: 与总样本数 n 解耦, 支持流式处理
- **计算效率**: 常数因子显著降低

数值实验



实验设置

三个层次的数值实验：

- ① 算法基准测试：流式矩阵更新，验证正交性保持与分解正确性
- ② 1D 参数化 PDE：对比批次 SVD、经典 Brand ISVD 和 Zhang ISVD
- ③ 2D 大规模 PDE：两个/三个参数模型，测量内存压缩比、离线时间加速比和降阶精度

加权内积矩阵 W 取为质量矩阵 M ，有限元框架实现。

参数化 PDE 模型

1D 变系数椭圆方程:

$$-\frac{d}{dx}\left((1+\mu x)\frac{du}{dx}\right) = 1, \quad x \in (0, 1), \quad u(0) = u(1) = 0,$$

参数 $\mu \in [0, 1]$, 等距取 200 个训练参数、100 个测试参数. 有限元离散单元数 $N = 500$.

2D 椭圆方程 (两个参数):


$$-\nabla \cdot ((1 + \mu_1 x + \mu_2 y) \nabla u) = 1, \quad (x, y) \in (0, 1)^2,$$

齐次 Dirichlet 边界条件. 40×40 网格, $N = 1600$, 参数 $\mu_1, \mu_2 \in [-0.2, 0.2]$.

2D 椭圆方程 (三个参数):


$$-\nabla \cdot ((1 + \mu_1 x + \mu_2 y + \mu_3 xy) \nabla u) = 1, \quad (x, y) \in (0, 1)^2,$$

更新后的 ISVD 算法正交性演化对比（基准测试）



结论： Brand 算法在 400 次更新后正交性急剧恶化；Zhang 改进算法始终保持在 10^{-14} 以下。

1D 参数化 PDE: 离线构基时间对比



- 批次 SVD 累计时间呈二次增长
- 经典 Brand ISVD 因正交性退化，后期时间急剧增加
- 400 步后 Brand 正交性误差 $\mathcal{E}_W(Q)$ 升至 10¹，导致数值不稳定


1D 参数化 PDE: Zhang ISVD 正交性

加权正交性误差:


$$\mathcal{E}_W(Q) = \|I - Q^T W Q\|_F$$

其中 $\|\cdot\|_F$ 为 Frobenius 范数, W 为质量矩阵.

- Zhang ISVD 在整个 550 次更新中 $\mathcal{E}_W(Q)$ 始终 $< 10^{-3}$
- 远优于经典 Brand 在 400 步后的完全发散



1D 参数化 PDE: 单步时间差分析




拟合曲线:

$$3.20 \times 10^{-8} k^2 - 3.75 \times 10^{-5} k + 2.81 \times 10^{-4}$$


在 1D 问题中, 实验中 ISVD 用时呈二次增长, 参数空间维数较低, 增量 SVD 的效率优势不明显. 因此在 2D 实验中, 我们将参数维数增至 23, 总快照数提升至 50,000, 以更充分地展示改进算法的性能.

2D 大规模 PDE (两个参数)



指标	Batch SVD	Zhang ISVD
峰值内存	1240 MB	~ 10 MB
压缩比	$1\times$	$120\times$
累计时间	较高	~ 8 秒 (近似线性)
重建误差	10^{-2} 量级	10^{-2} 量级

2D 大规模 PDE (三个参数)



指标	Batch SVD	Zhang ISVD
峰值内存	1240.3 MB	10.3 MB
压缩比	$1\times$	$120\times$
累计时间	12.39 s	8.43 s
最终重建误差	2.1×10^{-7}	1.5×10^{-5}

精度与稳定性讨论

- **正交性**: Zhang 改进 ISVD 加权正交性误差始终 $< 10^{-14}$ (基准测试) 或 $< 10^{-3}$ (1D PDE), 远优于经典 Brand 的发散.
- **内存**: 峰值内存压缩 120 倍, 存储节约率 $> 99\%$.
- **时间**: 累计时间加速比约 1.47 倍, 且呈近似线性增长.
- **精度**: 重建误差 1.5×10^{-5} vs. 批次 2.1×10^{-7} , 初始误差短暂上升后迅速收敛.

结论: 改进 ISVD 在内存、时间、精度之间找到了实用的平衡点, 特别适合大规模 many-query 场景.

结论与展望



结论

- ① 完整复现了加权 core SVD 框架与 Brand 经典增量算法，揭示了正交性退化的根源.
- ② 实现了 Zhang (2022) 改进算法，通过累积更新策略从根本上避免小正交矩阵连乘.
- ③ 数值实验表明：
 - 改进 ISVD 能够长期保持加权正交性
 - 峰值内存压缩一个数量级以上（最高 120 倍）
 - 离线时间显著缩短（加速比达 1.47 倍）
 - 逼近精度与批次 POD 相当
- ④ 为大规模参数化 PDE 的高效降阶提供了兼具数值稳定性与计算效率的可行方案.

未来展望

- **理论分析**: 建立累积更新策略的误差上界, 量化块大小与截断阈值的影响.
- **超大规模扩展**: 验证在三维非定常流动 ($N > 10^5$, $n > 10^6$) 中的可扩展性.
- **自适应策略**: 根据残差范数动态调整更新频率, 根据奇异值谱自动选择截断精度.
- **完全在线离线构基**: 与贪婪采样、后验误差估计器深度集成, 实现边采样边构基.

参考文献

-  J. S. Hesthaven, G. Rozza, B. Stamm, *Certified Reduced Basis Methods for Parametrized Partial Differential Equations*, Springer, 2015.
-  A. T. Patera, G. Rozza, *Reduced Basis Approximation and A Posteriori Error Estimation for Parametrized PDEs*, MIT Pappalardo Graduate Monographs, 2007.
-  H. Fareed, J. R. Singler, Y. Zhang, Incremental proper orthogonal decomposition for PDE simulation data, *Computers & Mathematics with Applications*, 75(6):1942-1960, 2018.
-  M. Brand, Incremental singular value decomposition of uncertain data with missing values, *ECCV*, 2002.
-  M. Brand, Fast low-rank modifications of the thin singular value decomposition, *Linear Algebra and its Applications*, 415(1):20-30, 2006.
-  Y. Zhang, An answer to an open question in the incremental SVD, *Numerical Linear Algebra with Applications*, 29(6):e2448, 2022.